

Hochschule für Technik Rapperswil HSR  
MRU: Sensors, Actors and Communication

## Studienarbeit

# Yolo auf Finger

im Studiengang Industrial Technologies

**eingereicht von:** Heinz Hofmann <hhofmann@hsr.ch>

**eingereicht am:** 9. Februar 2017

**Betreuer/Betreuerin:** Herr Prof. Dr. G. Schuster  
Frau T. Mendez

## Inhaltsverzeichnis

<b>1</b>	<b>Abstract</b>	<b>3</b>
1.1	Aufgabenstellung . . . . .	3
1.2	Vorgehen . . . . .	3
1.3	Fazit . . . . .	3
<b>2</b>	<b>Resultate</b>	<b>4</b>
2.1	Testvoraussetzungen . . . . .	4
2.2	Analyse . . . . .	4
2.2.1	Distanz . . . . .	4
2.2.2	Intersection Over Union IOU . . . . .	8
<b>3</b>	<b>Beispielkapitel</b>	<b>10</b>
3.1	Motivation . . . . .	10
3.1.1	Stand der Technik . . . . .	10

## Abbildungsverzeichnis

1	Bedeutung der normierten Distanzwerte in der realen Welt . .	5
2	Prediction knapp besser als Distanz=0.02 . . . . .	6
3	Prediction knapp schlechter als Distanz=0.02 . . . . .	6
4	Komplette Wahrscheinlichkeits-Dichte-Funktion der Distanz (Grenze: Dist=0.02) . . . . .	7
5	Wahrscheinlichkeits-Dichtefunktion der Distanz. Ausreisser nicht miteingerechnet (Grenze: Dist=0.02) . . . . .	7
6	Prediction knapp besser als IOU=0.4 . . . . .	9
7	Prediction knapp schlechter als IOU=0.4 . . . . .	9
8	Wahrscheinlichkeits-Dichte-Funktion der IOU (Grenze: IOU=0.4)	10
9	Dies ist eine Grafik als png . . . . .	11
10	Dies ist eine Grafik als pdf . . . . .	11

# 1 Abstract

## 1.1 Aufgabenstellung

Das Ziel dieser Projektarbeit ist es, herauszufinden, ob Yolo geeignet ist, die Fingerspitzen einer Hand in einem Bild zu klassifizieren und genau zu detektieren. Die Vorgaben, was die Genauigkeit betreffen liegen bei 0.1mm. Yolo ist eine Möglichkeit, um mittels Deep-Learning Objekte in einem Bild zu klassifizieren und gleichzeitig deren genaue Position zu detektieren. Daher auch der Ausdruck Yolo (You only look once). Yolo wurde als Mittel gewählt, weil es in diesem Bereich dem aktuellen Stand der Technik entspricht. Gerade die Geschwindigkeit dieses Netzwerks wird als extrem hoch angepriesen (bis zu 45fps). Diese Geschwindigkeit ist für die letztendliche Anwendung von hoher Wichtigkeit, weil es sich letzten Endes um eine Echtzeitanwendung handeln soll.

## 1.2 Vorgehen

## 1.3 Fazit

## 2 Resultate

### 2.1 Testvoraussetzungen

Das Netzwerk wurde auf 1'200'000 Bildern des ImageNet-1000-class-Datasets vortrainiert. Danach wurde es auf rund 13'900 Bildern aus Tabeas Box trainiert. Der Test wiederum wurde auf rund 1'500 Bilder ebenfalls aus Tabeas Box getestet. Diese Testbilder waren dem Algorithmus während des Lernprozesses nicht zugänglich und haben entsprechend keinen Einfluss auf den Lernprozess genommen. Ausserdem wurden diese Bilder so gewählt, dass Sie nicht gleichzeitig aufgenommen wurden. Dies verhindert, dass fast identische Bilder im Training und im Test vorkommen.

### 2.2 Analyse

Um die Genauigkeit der Predictions unseres Neuronalen Netzwerkes möglichst genau beschreiben zu können wurden die zwei Werte Distanz und IOU gewählt. Obwohl die beiden Werte korrelieren sagt jeder für sich nicht die volle Wahrheit über die Genauigkeit der Vorhersagen aus. Die Distanz ist für die geplante Anwendung der wesentlichere Wert, weil diese Informationen über den Standort des Fingers im Bild preisgibt. Die IOU ist mit der Distanz klar korreliert, denn ist die Distanz zu gross, ist die IOU schnell gleich Null. Sobald die Boundingbox der Prediction und die Boundingbox des Labels sich beginnen zu überlappen sagt die IOU etwas über die korrekte Vorhersage von Breite und Höhe der Boundingbox aus. Auch darüber ob die Box am richtigen Ort liegt, können aufgrund der IOU vage Annahmen getroffen werden. Aber wie gesagt, die Distanz ist dafür der sicherere Wert.

#### 2.2.1 Distanz

Die Distanz beschreibt die normierte Differenz zwischen dem Zentrumspunkt des Labels und dem Zentrumspunkt der Vorhersage. Sämtliche Distanzen wurden so normiert, dass die Höhe des Bildes und auch die Breite gleich eins sind. Die maximale Distanz zwischen zwei Punkten ist also die Diagonale über ein Bild, welche entsprechend  $\sqrt{2}$  ist. Was diese Normierten Distanzen in der realen Welt bedeuten ist auf Abbildung 1 erklärt. Zum Vergleich, ein Menschlicher Zeigefinger ist zwischen 10 und 20 mm breit. Eine normierte Distanz von 0.02 entspricht auf unserem Versuchsaufbau somit ziemlich genau der Breite eines menschlichen Fingers.




Abbildung 1: Bedeutung der normierten Distanzwerte in der realen Welt

Um die Resultate in gut und schlecht einteilen zu können wurde ein Threshold von 0.02 definiert. Die Definition dieses Thresholds wurde gemacht, indem Bilder zusammen mit der entsprechenden Distanz analysiert wurden. Der Wert 0.02 entspricht somit derjenigen Distanz, welche gerade noch knapp annehmbar ist, um einen Finger als detektiert gelten zu lassen. Um ein Gefühl für diese Distanzen zu kriegen lohnt es sich die Abbildungen 2 & 3 anzusehen, welche Bilder zeigen, die eine Distanz nahe dieses Thresholds aufweisen.

Um die Verteilung der Distanzen gut verstehen zu können, ist in Abbildung 4 eine Wahrscheinlichkeitsdichte der Distanzen im Testset zu sehen. Diese Dichtefunktion wurde erst nach der Bestimmung des Thresholds erzeugt und zeigt, dass rund 73% der Distanzen kürzer sind als 0.02 und somit die entsprechenden Finger erfolgreich erkannt wurden.

Erstaunlich ist auch, dass die Distanzen, welche grösser als 0.25 sind in der Wahrscheinlichkeitsdichte in kleinen Bündeln vorkommen. Dies lässt darauf schliessen, dass die Trainingsdaten nicht komplett Bias-frei sind. Nach kurzer Kontrolle konnte tatsächlich festgestellt werden, dass z.B. bei einer Distanz von 0.6 immer ein bestimmter Punkt des Hintergrundes vorhergesagt wurde, welcher tatsächlich ganz selten in den Labels als Finger markiert wurde.




Abbildung 2: Prediction knapp besser als Distanz=0.02




Abbildung 3: Prediction knapp schlechter als Distanz=0.02




Abbildung 4: Komplette Wahrscheinlichkeits-Dichte-Funktion der Distanz (Grenze: Dist=0.02)




Abbildung 5: Wahrscheinlichkeits-Dichtefunktion der Distanz. Ausreisser nicht miteingerechnet (Grenze: Dist=0.02)



Um die Statistik nicht von Ausreissern, welche aufgrund von falschen Labels entstanden sind verfälschen zu lassen, wurde wie in Abbildung 5 noch eine zweite Wahrscheinlichkeitsdichte-Funktion erstellt. Spannend: Der Mittelwert ist sofort um einen Drittel kleiner als zuvor.

### 2.2.2 Intersection Over Union IOU

Die IOU beschreibt die Überlappung der vorhergesagten Boundingbox und der Boundingbox des Labels. Daher sagt die IOU einerseits etwas über die korrekte Grösse der Boundingbox, sowie deren korrekte Lage aus. Um wieder etwas über gut und schlecht aussagen zu können, wurde wieder ein Threshold definiert (0.4). Da durch die IOU wie erwähnt mehrere Faktoren beschrieben werden, ist die Grenze verschwommener. So gibt es nach menschlicher Ansicht hervorragende Vorhersagen, welche eine IOU von 0.3 haben und wiederum mässige Vorhersagen mit einer IOU von nahezu 0.4. Um ein Gefühl für diesen Threshold zu kriegen lohnt es sich die Abbildungen 6 & 7 zu berücksichtigen. So fiel die Entscheidung den Threshold konservativ zu wählen, sodass nur Werte als gut erachtet werden könne, welche auch gut sind.

Auch für die IOU gibt es zur Übersicht eine Wahrscheinlichkeitsdichte die in Abbildung 8 betrachtet werden kann. Aus dieser Grafik kann gelesen werden, dass rund 18% der Vorhersagen klar falsch sind, weil die IOU nur null ist, wenn sich die beiden Boundingboxen nicht berühren. Entsprechend kann gesagt werden, dass rund 82% der Vorhersagen zumindest sehr grob richtig sind, weil sich bei diesen 82% die Boundingboxen von Label und Prediction zumindest ein ganz kleines bisschen überlappen.



Abbildung 6: Prediction knapp besser als  $\text{IOU}=0.4$ Abbildung 7: Prediction knapp schlechter als  $\text{IOU}=0.4$

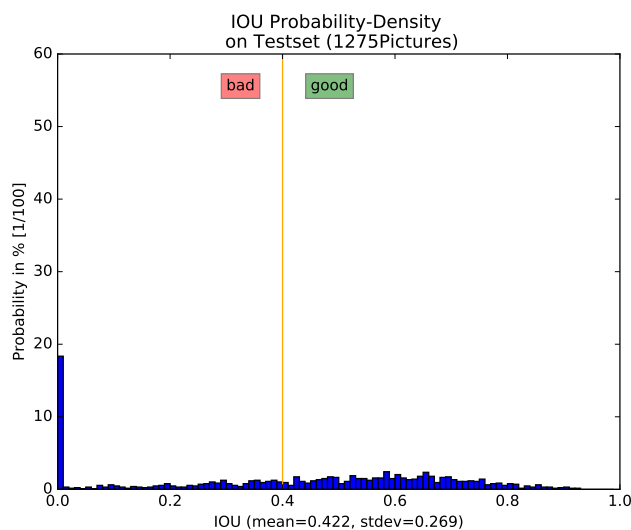


Abbildung 8: Wahrscheinlichkeits-Dichte-Funktion der IOU (Grenze: IOU=0.4)

## 3 Beispielkapitel

Dies ist ein weiterer Satz

Wir machen hier weiter mit folgender Fussnote<sup>1</sup>. Natürlich können viele verschiedene Sätze entsprechende Fussnoten<sup>2</sup> haben.

Ich möchte aber auch auf entsprechen die 1. Fussnote auf Seite 10 verweisen.

Auf jedem Fall wird dieser Punkt im Kapitel 3.1 auf Seite ?? beschrieben.

### 3.1 Motivation

#### 3.1.1 Stand der Technik

Dies ist ein Satz. Dies ist Satz Nr. 2 Jeder Satz kommt auf eine eigene Zeile. Soll ein Absatz gemacht werden, muss eine Leerzeile eingefügt werden.

Dies ist Satz Nr.3 Aber jetzt habe ich eine komische einrückung beim Satzstart...? Naja, da werden wir sicher auch noch herausfinden, warum dies so ist.

So sollte alles auf git schön anzusehen sein...

<sup>1</sup>Damit wird die entsprechende Fussnote beschrieben.

<sup>2</sup>Auf jeden Fall funktioniert das..

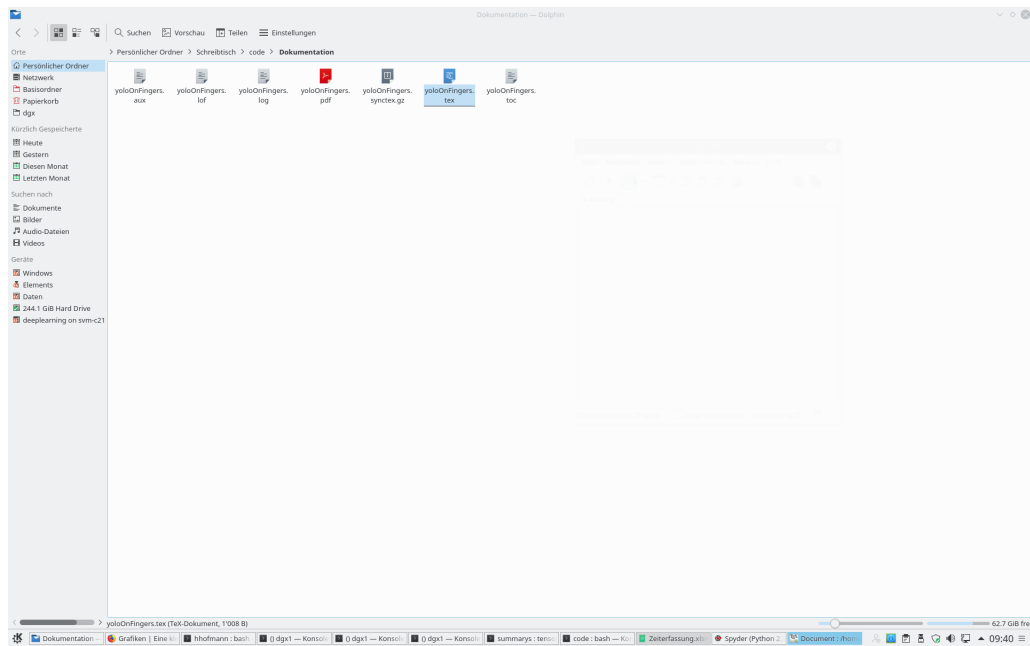


Abbildung 9: Dies ist eine Grafik als png




Abbildung 10: Dies ist eine Grafik als pdf

Weiterhin wollen wir an dieser Stelle Bezug auf die Grafik 9 auf Seite 11 nehmen, was uns